g33_m3ep2_eq4_notebook

April 17, 2026

0.1 Sobre el data Set

El conjunto de datos de FIFA19 es una compilación exhaustiva de atributos de jugadores, estadísticas y otra información relevante del videojuego. Incluye detalles sobre más de 17,000 futbolistas con 75 atributos, abarcando aspectos como edad, posición de juego, calificaciones generales, potencial y una variedad de atributos de habilidad tanto ofensivos como defensivos. Estos atributos de habilidad incluyen, entre otros, velocidad, dribbling, pase, disparo, defensa, y habilidades de portero.

El propósito de este análisis es identificar segmentos de jugadores dentro del conjunto de datos que compartan características similares. Al agrupar a los jugadores de esta manera, se busca descubrir un equilibrio que, a futuro, permita crear combinaciones óptimas de jugadores en un equipo ficticio, maximizando así sus potenciales colaborativos y rendimiento conjunto.

[132]:
```
# Librerías

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns


random_seed = 333 # Semilla para reproducibilidad de resultados
np.random.seed(random_seed) # Para reproducibilidad
```

0.1.1 Análisis exploratorio de los datos

[133]:
```
# 1. Carga de datos
df = pd.read_csv('FIFA19-DS.csv', index_col=0)
```

[134]:
```
# 2. Exploración de datos
print(df.shape)
display(df.head())
```

```
(17140, 75)

        Age  Overall  Potential      Value    Wage  Special  \
ID
158023   31       94         94  110500000  565000     2202
20801    33       94         94   77000000  405000     2228
```

```
190871   26       92         93  118500000  290000     2143
192985   27       91         92  102000000  355000     2281
183277   27       91         91   93000000  340000     2142

        International Reputation  Weak Foot  Skill Moves  Work Rate  …  \
ID                                                                    …
158023                         5          4            4          4  …
20801                          5          4            5          6  …
190871                         5          5            5          7  …
192985                         4          5            4          8  …
183277                         4          4            4          7  …

        StandingTackle  SlidingTackle  GKDiving  GKHandling  GKKicking  \
ID
158023              28             26         6          11         15
20801               31             23         7          11         15
190871              24             33         9           9         15
192985              58             51        15          13          5
183277              27             22        11          12          6

        GKPositioning  GKReflexes  Preferred Foot  Body Type  Position
ID
158023             14           8            Left       Lean        ST
20801              14          11           Right     Normal        ST
190871             15          11           Right       Lean        AM
192985             10          13           Right     Normal        MF
183277              8           8           Right     Normal        ST

[5 rows x 75 columns]
```

[135]:
```python
# Identificación de tipo y cantidad de datos faltantes
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 17140 entries, 158023 to 242844
Data columns (total 75 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Age                       17140 non-null  int64
 1   Overall                   17140 non-null  int64
 2   Potential                 17140 non-null  int64
 3   Value                     17140 non-null  int64
 4   Wage                      17140 non-null  int64
 5   Special                   17140 non-null  int64
 6   International Reputation  17140 non-null  int64
 7   Weak Foot                 17140 non-null  int64
 8   Skill Moves               17140 non-null  int64
 9   Work Rate                 17140 non-null  int64
```

```
10  Height                  17140 non-null  float64
11  Weight                  17140 non-null  int64
12  LS                      15298 non-null  float64
13  ST                      15298 non-null  float64
14  RS                      15298 non-null  float64
15  LW                      15298 non-null  float64
16  LF                      15298 non-null  float64
17  CF                      15298 non-null  float64
18  RF                      15298 non-null  float64
19  RW                      15298 non-null  float64
20  LAM                     15298 non-null  float64
21  CAM                     15298 non-null  float64
22  RAM                     15298 non-null  float64
23  LM                      15298 non-null  float64
24  LCM                     15298 non-null  float64
25  CM                      15298 non-null  float64
26  RCM                     15298 non-null  float64
27  RM                      15298 non-null  float64
28  LWB                     15298 non-null  float64
29  LDM                     15298 non-null  float64
30  CDM                     15298 non-null  float64
31  RDM                     15298 non-null  float64
32  RWB                     15298 non-null  float64
33  LB                      15298 non-null  float64
34  LCB                     15298 non-null  float64
35  CB                      15298 non-null  float64
36  RCB                     15298 non-null  float64
37  RB                      15298 non-null  float64
38  Crossing                17140 non-null  int64
39  Finishing               17140 non-null  int64
40  HeadingAccuracy         17140 non-null  int64
41  ShortPassing            17140 non-null  int64
42  Volleys                 17140 non-null  int64
43  Dribbling               17140 non-null  int64
44  Curve                   17140 non-null  int64
45  FKAccuracy              17140 non-null  int64
46  LongPassing             17140 non-null  int64
47  BallControl             17140 non-null  int64
48  Acceleration            17140 non-null  int64
49  SprintSpeed             17140 non-null  int64
50  Agility                 17140 non-null  int64
51  Reactions               17140 non-null  int64
52  Balance                 17140 non-null  int64
53  ShotPower               17140 non-null  int64
54  Jumping                 17140 non-null  int64
55  Stamina                 17140 non-null  int64
56  Strength                17140 non-null  int64
57  LongShots               17140 non-null  int64
```

```
 58  Aggression                17140 non-null  int64
 59  Interceptions             17140 non-null  int64
 60  Positioning               17140 non-null  int64
 61  Vision                    17140 non-null  int64
 62  Penalties                 17140 non-null  int64
 63  Composure                 17140 non-null  int64
 64  Marking                   17140 non-null  int64
 65  StandingTackle            17140 non-null  int64
 66  SlidingTackle             17140 non-null  int64
 67  GKDiving                  17140 non-null  int64
 68  GKHandling                17140 non-null  int64
 69  GKKicking                 17140 non-null  int64
 70  GKPositioning             17140 non-null  int64
 71  GKReflexes                17140 non-null  int64
 72  Preferred Foot            17140 non-null  object
 73  Body Type                 17140 non-null  object
 74  Position                  17140 non-null  object
dtypes: float64(27), int64(45), object(3)
memory usage: 9.9+ MB
None
```

[136]:
```python
# Columnas donde hay nulos
df.isnull().sum().sort_values(ascending=False).head(28)
```

[136]:
```
RB             1842
RW             1842
CAM            1842
RAM            1842
LM             1842
LCM            1842
RCM            1842
RM             1842
LWB            1842
LDM            1842
CDM            1842
RDM            1842
RWB            1842
LB             1842
LCB            1842
CB             1842
RCB            1842
LAM            1842
CM             1842
RF             1842
LF             1842
LW             1842
RS             1842
```

```
ST              1842
LS              1842
CF              1842
LongShots          0
Positioning        0
dtype: int64
```

[137]:
```python
# Configuramos el estilo visual
sns.set(style="whitegrid")

# Creamos una figura con 3 subgráficos para comparar
plt.figure(figsize=(18, 5))

# 1. Distribución de la Edad
plt.subplot(1, 3, 1)
sns.histplot(df['Age'], kde=True, color='skyblue')
plt.title('Distribución de la Edad')

# 2. Distribución de Overall (Calificación Actual)
plt.subplot(1, 3, 2)
sns.histplot(df['Overall'], kde=True, color='salmon')
plt.title('Distribución de Calificación General')

# 3. Distribución de Potential (Calificación Futura)
plt.subplot(1, 3, 3)
sns.histplot(df['Potential'], kde=True, color='lightgreen')
plt.title('Distribución del Potencial')

plt.tight_layout()
plt.show()
```

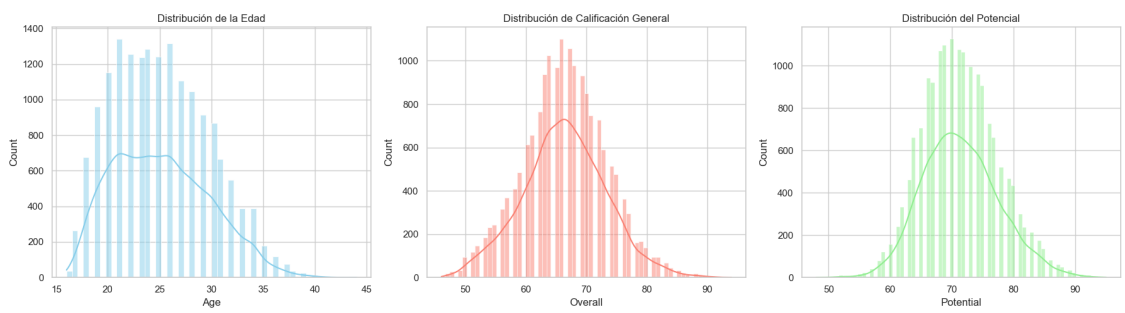

[138]:
```python
# 1. Separar Porteros de Jugadores de Campo
# Basándonos en la columna 'Position'
df_field = df[df['Position'] != 'GK'].copy()
df_gk = df[df['Position'] == 'GK'].copy()
```

```python
print(f"Jugadores de campo: {df_field.shape[0]}")
print(f"Porteros: {df_gk.shape[0]}")

# 2. Verificar nulos restantes en jugadores de campo
# Si los nulos eran los porteros, df_field debería estar casi limpio
print("\nNulos en 'Finishing' (jugadores de campo):", df_field['Finishing'].
 ↪isnull().sum())
```

```
Jugadores de campo: 15298
Porteros: 1842

Nulos en 'Finishing' (jugadores de campo): 0
```

[139]:
```python
df_field.head()
```

[139]:

	Age	Overall	Potential	Value	Wage	Special	\
ID							
158023	31	94	94	110500000	565000	2202	
20801	33	94	94	77000000	405000	2228	
190871	26	92	93	118500000	290000	2143	
192985	27	91	92	102000000	355000	2281	
183277	27	91	91	93000000	340000	2142	

	International Reputation	Weak Foot	Skill Moves	Work Rate	…	\
ID					…	
158023	5	4	4	4	…	
20801	5	4	5	6	…	
190871	5	5	5	7	…	
192985	4	5	4	8	…	
183277	4	4	4	7	…	

	StandingTackle	SlidingTackle	GKDiving	GKHandling	GKKicking	\
ID						
158023	28	26	6	11	15	
20801	31	23	7	11	15	
190871	24	33	9	9	15	
192985	58	51	15	13	5	
183277	27	22	11	12	6	

	GKPositioning	GKReflexes	Preferred Foot	Body Type	Position
ID					
158023	14	8	Left	Lean	ST
20801	14	11	Right	Normal	ST
190871	15	11	Right	Lean	AM
192985	10	13	Right	Normal	MF
183277	8	8	Right	Normal	ST

```
[5 rows x 75 columns]
```

[140]:
```python
df_field.describe()
```

[140]:
```
                Age       Overall     Potential         Value           Wage  \
count  15298.000000  15298.000000  15298.000000  1.529800e+04   15298.000000
mean      25.053340     66.588704     71.570794  2.589071e+06   10373.055301
std        4.542381      6.797187      6.099113  5.831828e+06   23036.206191
min       16.000000     46.000000     48.000000  0.000000e+00       0.000000
25%       21.000000     62.000000     67.000000  3.500000e+05    1000.000000
50%       25.000000     67.000000     71.000000  7.500000e+05    3000.000000
75%       28.000000     71.000000     75.000000  2.300000e+06   10000.000000
max       41.000000     94.000000     95.000000  1.185000e+08  565000.000000

            Special  International Reputation     Weak Foot   Skill Moves  \
count  15298.000000              15298.000000  15298.000000  15298.000000
mean    1672.443391                  1.119297      3.013139      2.541443
std      196.709750                  0.403074      0.638502      0.620319
min     1000.000000                  1.000000      1.000000      2.000000
25%     1532.000000                  1.000000      3.000000      2.000000
50%     1676.000000                  1.000000      3.000000      2.000000
75%     1810.000000                  1.000000      3.000000      3.000000
max     2346.000000                  5.000000      5.000000      5.000000

          Work Rate  …     Penalties     Composure       Marking  \
count  15298.000000  …  15298.000000  15298.000000  15298.000000
mean       4.849784  …     52.252386     60.533272     51.442738
std        1.678181  …     12.518438     10.166900     17.179121
min        0.000000  …     12.000000     22.000000     10.000000
25%        4.000000  …     43.000000     54.000000     38.000000
50%        4.000000  …     52.000000     61.000000     56.000000
75%        7.000000  …     62.000000     68.000000     65.000000
max        8.000000  …     92.000000     96.000000     94.000000

       StandingTackle  SlidingTackle      GKDiving    GKHandling  \
count    15298.000000   15298.000000  15298.000000  15298.000000
mean        52.101582      49.795725     10.511439     10.558374
std         19.110227      19.116446      3.096290      3.076654
min         10.000000      10.000000      1.000000      1.000000
25%         35.000000      32.000000      8.000000      8.000000
50%         59.000000      56.000000     10.000000     11.000000
75%         67.000000      65.000000     13.000000     13.000000
max         93.000000      91.000000     37.000000     33.000000

          GKKicking  GKPositioning    GKReflexes
count  15298.000000   15298.000000  15298.000000
mean      10.557458      10.536410     10.514185
```

```
std        3.147400       3.085543      3.105028
min        1.000000       1.000000      1.000000
25%        8.000000       8.000000      8.000000
50%       11.000000      11.000000     10.000000
75%       13.000000      13.000000     13.000000
max       41.000000      33.000000     37.000000

[8 rows x 72 columns]
```

[141]:
```python
# Grafica las distribuciones de las 75 variables para jugadores de campo
variables_field = df_field.columns[1:-1]  # Excluyendo 'Position'
num_vars = len(variables_field)
cols = 5
rows = (num_vars // cols) + (num_vars % cols > 0)
plt.figure(figsize=(20, rows * 4))
for i, var in enumerate(variables_field):
    plt.subplot(rows, cols, i + 1)
    sns.histplot(df_field[var], kde=True, color='lightblue')
    plt.title(f'Distribución de {var}')
    plt.xlabel('')
    plt.ylabel('')
plt.tight_layout()
plt.show()
```

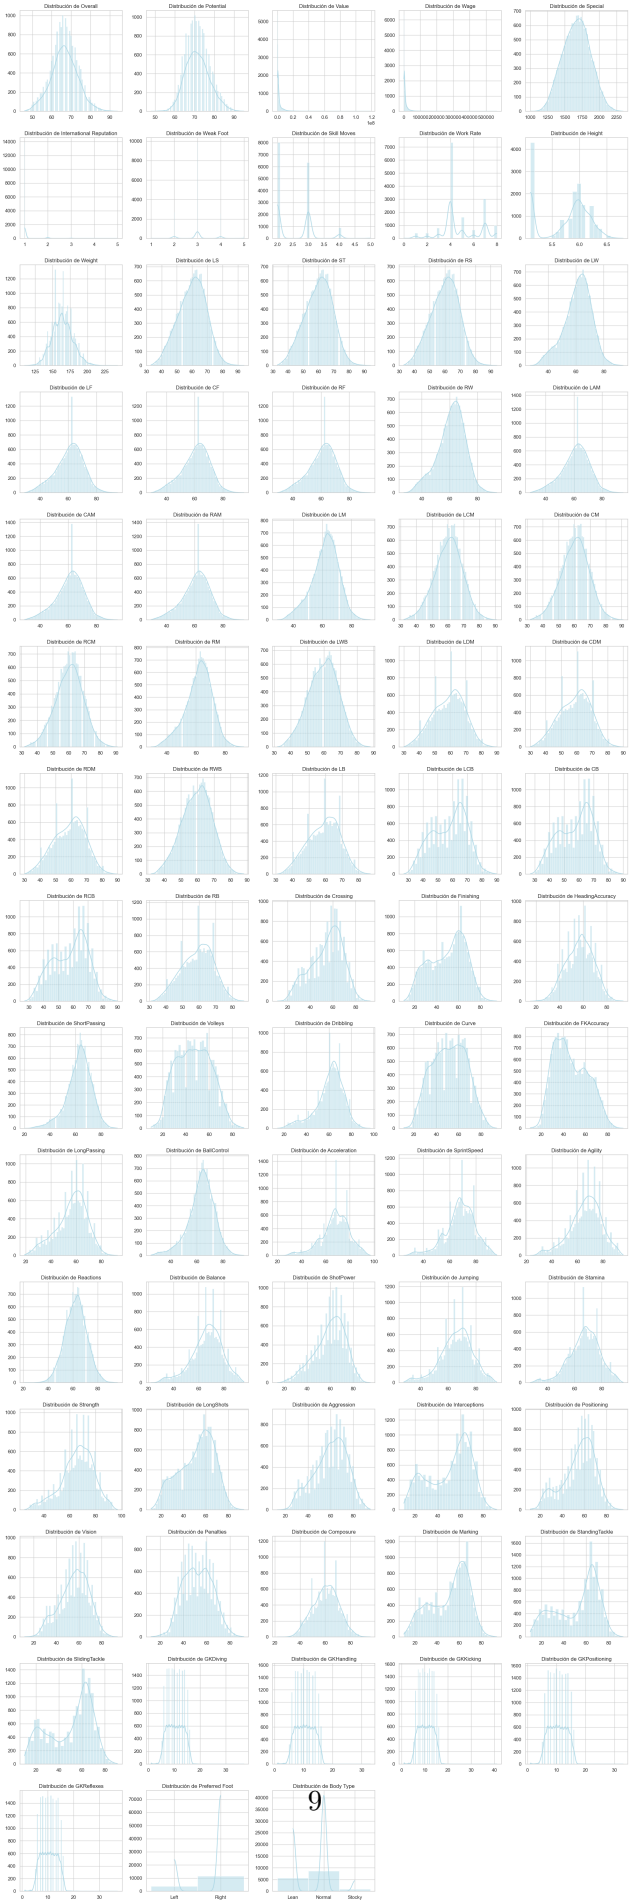
Distribución de Overall
Distribución de Potential
Distribución de Value
Distribución de Wage
Distribución de Special
Distribución de International Reputation
Distribución de Weak Foot
Distribución de Skill Moves
Distribución de Work Rate
Distribución de Height
Distribución de Weight
Distribución de LS
Distribución de ST
Distribución de RS
Distribución de LW
Distribución de LF
Distribución de CF
Distribución de RF
Distribución de RW
Distribución de LAM
Distribución de CAM
Distribución de RAM
Distribución de LM
Distribución de LCM
Distribución de CM
Distribución de RCM
Distribución de RM
Distribución de LWB
Distribución de LDM
Distribución de CDM
Distribución de RDM
Distribución de RWB
Distribución de LB
Distribución de LCB
Distribución de CB
Distribución de RCB
Distribución de RB
Distribución de Crossing
Distribución de Finishing
Distribución de HeadingAccuracy
Distribución de ShortPassing
Distribución de Volleys
Distribución de Dribbling
Distribución de Curve
Distribución de FKAccuracy
Distribución de LongPassing
Distribución de BallControl
Distribución de Acceleration
Distribución de SprintSpeed
Distribución de Agility
Distribución de Reactions
Distribución de Balance
Distribución de ShotPower
Distribución de Jumping
Distribución de Stamina
Distribución de Strength
Distribución de LongShots
Distribución de Aggression
Distribución de Interceptions
Distribución de Positioning
Distribución de Vision
Distribución de Penalties
Distribución de Composure
Distribución de Marking
Distribución de StandingTackle
Distribución de SlidingTackle
Distribución de GKDiving
Distribución de GKHandling
Distribución de GKKicking
Distribución de GKPositioning
Distribución de GKReflexes
Distribución de Preferred Foot
Distribución de Body Type
Left
Right
Lean
Normal
Stocky

[142]:
```
# Comprobamos nulos en el dataset de jugadores de campo (df_field)
nulos_restantes = df_field[['Finishing', 'ShortPassing', 'Vision',␣
↪'Interceptions']].isnull().sum()

print("Nulos en el dataset de jugadores de campo:")
print(nulos_restantes)

if nulos_restantes.sum() == 0:
    print("\n¡Confirmado! Los nulos eran efectivamente los porteros. El set de␣
↪campo está limpio.")
else:
    print("\n Aún quedan nulos. Necesitamos revisar si hay registros␣
↪incompletos en jugadores de campo.")
```

```
Nulos en el dataset de jugadores de campo:
Finishing        0
ShortPassing     0
Vision           0
Interceptions    0
dtype: int64

¡Confirmado! Los nulos eran efectivamente los porteros. El set de campo está
limpio.
```

0.2 Enfoque completo - PCA

[143]:
```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

# 1. Seleccionamos todas las variables numéricas de habilidad (skills)
# Excluimos IDs, nombres y variables que no sean de rendimiento técnico
X_completo = df_field.select_dtypes(include=['int64', 'float64']).
↪drop(columns=['Overall', 'Potential'], errors='ignore')

# 2. Escalado (Fundamental para PCA)
X_comp_scaled = StandardScaler().fit_transform(X_completo)

# 3. Aplicamos PCA para ver la Varianza Explicada Acumulada
# Queremos ver cuántos componentes se necesitan para llegar al ~80%
pca_full = PCA()
pca_full.fit(X_comp_scaled)

import numpy as np
varianza_acumulada = np.cumsum(pca_full.explained_variance_ratio_)
```

```
# Visualizamos para tomar la decisión de rigor
plt.figure(figsize=(8, 5))
plt.plot(range(1, len(varianza_acumulada) + 1), varianza_acumulada, marker='o')
plt.axhline(y=0.8, color='r', linestyle='--')
plt.title('Varianza Explicada Acumulada (Dataset Completo)')
plt.xlabel('Número de Componentes')
plt.ylabel('Varianza Explicada')
plt.grid(True)
plt.show()

# 4. Elegimos el número de componentes (supongamos que con 5-8 basta)
n_comp = np.argmax(varianza_acumulada >= 0.8) + 1
print(f"Para mantener el rigor con el 80% de la varianza, usaremos {n_comp}␣
↪componentes.")

pca_final = PCA(n_components=n_comp)
X_reducido = pca_final.fit_transform(X_comp_scaled)
```

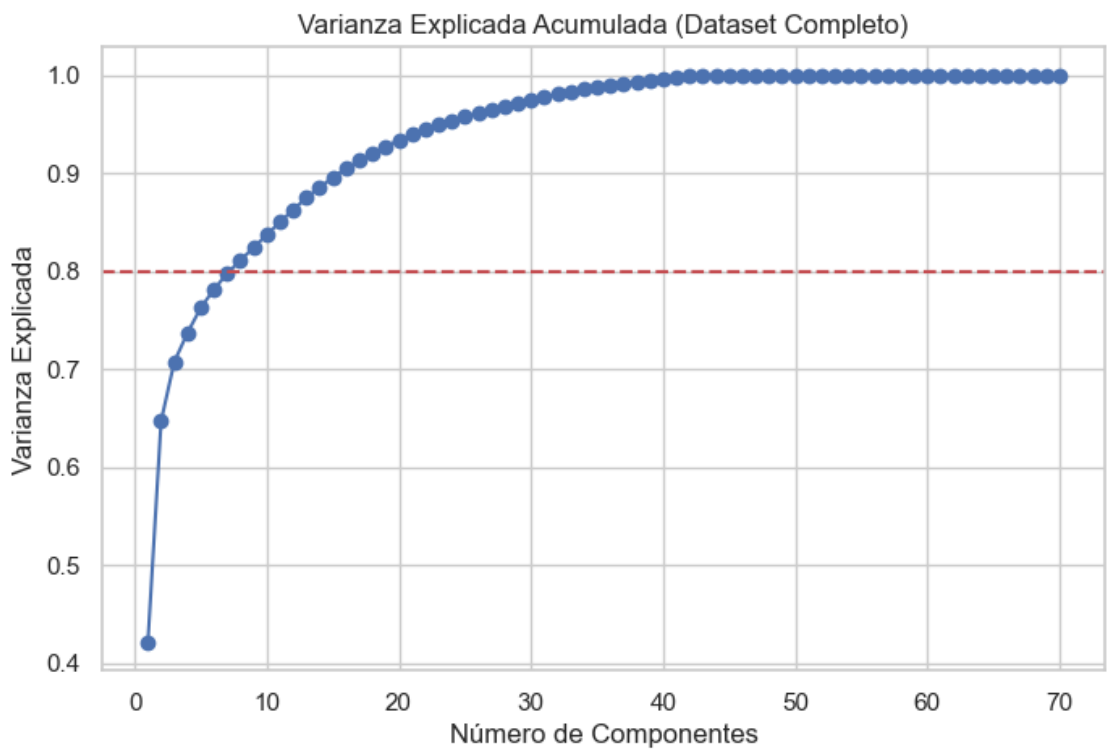


```
Para mantener el rigor con el 80% de la varianza, usaremos 8 componentes.
```

[144]:
```
# 1. Obtenemos las cargas (loadings)
loadings = pd.DataFrame(
    pca_final.components_.T,
```

```
    columns=[f'PC{i+1}' for i in range(n_comp)],
    index=X_completo.columns
)

# 2. Vemos qué variables dominan el PC1 y el PC2
print("Top variables en PC1 (Habilidad General):")
print(loadings['PC1'].sort_values(ascending=False).head(5))

print("\nTop variables en PC2 (Perfil Físico/Defensivo):")
print(loadings['PC2'].sort_values(ascending=False).head(5))
```

```
Top variables en PC1 (Habilidad General):
RAM    0.179665
CAM    0.179665
LAM    0.179665
LM     0.179566
RM     0.179566
Name: PC1, dtype: float64

Top variables en PC2 (Perfil Físico/Defensivo):
RCB               0.246854
LCB               0.246854
CB                0.246854
StandingTackle    0.240110
Interceptions     0.237767
Name: PC2, dtype: float64
```

0.2.1 Cargas factoriales sobre características

- PC1: Pesan más los grupos con corte ofensiva (strikers y medio campistas defensivos)
- PC2: Pesan más aquellas características de jugadores de corte defensivo.

[145]:
```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, calinski_harabasz_score,␣
 ↪davies_bouldin_score
import pandas as pd

results = []
k_range = range(2, 11)

for k in k_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = km.fit_predict(X_reducido)

    results.append({
        'K': k,
        'Inertia': km.inertia_,
        'Silhouette': silhouette_score(X_reducido, labels),
```

```
        'Calinski_Harabasz': calinski_harabasz_score(X_reducido, labels),
        'Davies_Bouldin': davies_bouldin_score(X_reducido, labels)
    })

df_metrics = pd.DataFrame(results)

# Visualización comparativa
fig, axs = plt.subplots(2, 2, figsize=(15, 10))
plt.subplots_adjust(hspace=0.3)

# 1. Elbow Method (Inertia)
axs[0, 0].plot(df_metrics['K'], df_metrics['Inertia'], 'o-', color='blue')
axs[0, 0].set_title('Método del Codo (Inertia)')
axs[0, 0].set_xlabel('K')

# 2. Silhouette Score
axs[0, 1].plot(df_metrics['K'], df_metrics['Silhouette'], 'o-', color='red')
axs[0, 1].set_title('Silhouette Score (Máximo es mejor)')
axs[0, 1].set_xlabel('K')

# 3. Calinski-Harabasz Index
axs[1, 0].plot(df_metrics['K'], df_metrics['Calinski_Harabasz'], 'o-',␣
 ↪color='green')
axs[1, 0].set_title('Calinski-Harabasz (Máximo es mejor)')
axs[1, 0].set_xlabel('K')

# 4. Davies-Bouldin Index
axs[1, 1].plot(df_metrics['K'], df_metrics['Davies_Bouldin'], 'o-',␣
 ↪color='purple')
axs[1, 1].set_title('Davies-Bouldin (Mínimo es mejor)')
axs[1, 1].set_xlabel('K')

plt.show()
```

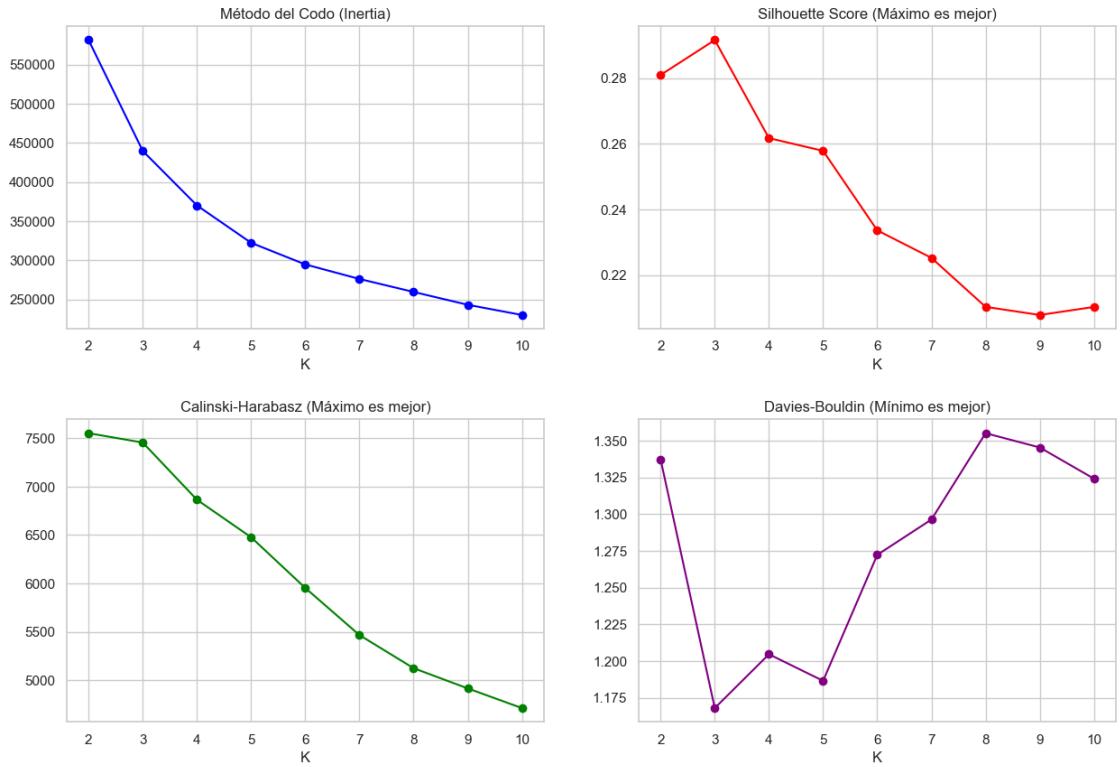

0.3 Evaluación de Clústeres con las técnicas vistas en clase

Basándonos en lo que vimos en los loadings (PC1 para creación y PC2 para defensa) y en las técnicas de evaluación arriba se describen tres grupos que probablemente se distribuyen así:

- Cluster de Especialización Defensiva: Jugadores con alto valor en PC2. Son los encargados de la contención, el juego aéreo y las intercepciones. Aquí se consolidan los defensas centrales y los mediocentros de corte.
- Cluster de Especialización Ofensiva / Creativa: Jugadores con alto valor en PC1. Son los arquitectos y finalizadores. Este grupo aglutina desde el mediapunta creativo hasta el extremo veloz y el delantero centro, ya que todos comparten la "habilidad técnica superior".
- Cluster de Transición y Soporte: Es el grupo central. Son jugadores polivalentes, con estadísticas balanceadas (box-to-box, laterales equilibrados) que no tienen un sesgo extremo hacia la creación pura o la defensa pura.

0.4 Técnica de clustering: K- Means

[146]:
```
# 1. Entrenamiento final con K=3 sobre los componentes del PCA
kmeans_3 = KMeans(n_clusters=3, random_state=42, n_init=10)
df_field['Cluster_3'] = kmeans_3.fit_predict(X_reducido)

# 2. Visualización en el plano de los Componentes Principales
```

```
plt.figure(figsize=(12, 8))
scatter = plt.scatter(X_reducido[:, 0], X_reducido[:, 1],
            c=df_field['Cluster_3'], cmap='Set1', alpha=0.5, s=30)

plt.xlabel('PC1: Habilidad Técnica y Creatividad')
plt.ylabel('PC2: Rigor Defensivo y Posicionamiento')
plt.title('Segmentación Óptima de Jugadores (K=3) ex-post PCA')
plt.colorbar(scatter, label='Cluster')
plt.grid(True, linestyle='--', alpha=0.6)

# Añadimos los centroides para marcar el "corazón" de cada grupo
centroides = kmeans_3.cluster_centers_
plt.scatter(centroides[:, 0], centroides[:, 1], marker='X', s=200, c='black',␣
 ↪label='Centroides')
plt.legend()
plt.show()
```

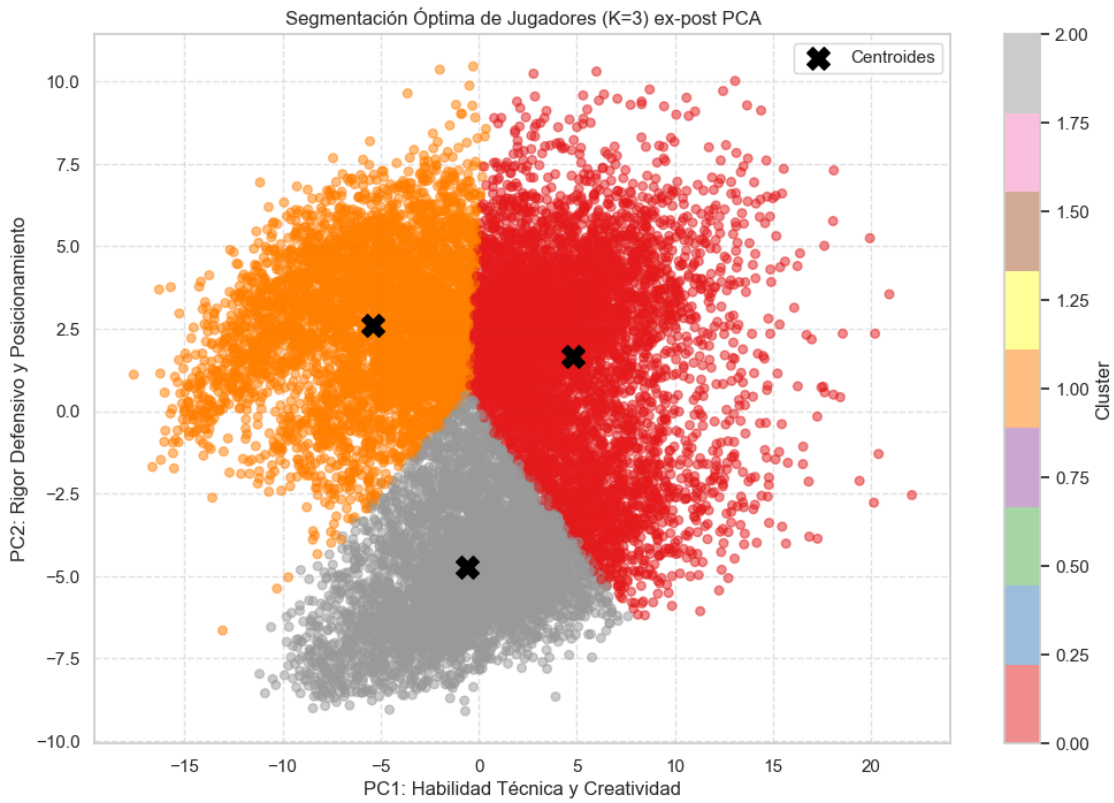

[147]:
```
variables_finales = [
    'Overall', 'Potential', 'Finishing',
    'ShortPassing', 'Vision', 'Interceptions', 'Stamina'
]
```

```
# 1. Calculamos las medias de las variables originales para los 3 nuevos␣
↪clusters
# Usamos las variables que definimos al inicio para que la tabla sea legible
perfil_final = df_field.groupby('Cluster_3')[variables_finales].mean()

# 2. Añadimos el conteo de jugadores para ver la distribución de la población
perfil_final['Cantidad'] = df_field['Cluster_3'].value_counts()

# 3. Ordenamos por Overall para entender la jerarquía
print("Tabla de Perfiles Tácticos Finales (K=3):")
df_resumen = perfil_final.sort_values(by='Overall', ascending=False).round(2)
display(df_resumen)
```

```
Tabla de Perfiles Tácticos Finales (K=3):

           Overall  Potential  Finishing  ShortPassing  Vision  Interceptions  \
Cluster_3
0            71.44      74.18      56.44         70.60   65.45          60.25
2            63.75      70.46      60.40         59.33   56.19          28.53
1            63.36      69.43      31.55         56.75   43.25          60.57

           Stamina  Cantidad
Cluster_3
0            74.04      5883
2            61.93      4688
1            64.86      4727
```

[148]:
```
# Veamos cuántos jugadores hay de cada posición en cada cluster para entender␣
↪mejor su ADN futbolístico
posiciones_por_cluster = df_field.groupby(['Cluster_3', 'Position']).size().
↪unstack(fill_value=0)
print("Distribución de Posiciones por Cluster (K=3):")
display(posiciones_por_cluster)
```

```
Distribución de Posiciones por Cluster (K=3):

Position     AM    DF   DM    MF    ST
Cluster_3
0           641  1725  899  2176   442
1            20  3760  469   467    11
2          1019    40   24  1562  2043
```

0.4.1 Perfilamiento Detallado de los Grupos (Clusters)

Basado en la segmentación ex-post PCA y la tabla de medias obtenida, se identifican tres arquetipos funcionales:

- **Cluster 0**: La Columna Vertebral y Élite Técnica

Perfil Estadístico: Es el grupo con el Overall (71.44) y Potential (74.18) más altos. Destaca por una capacidad de distribución superior (ShortPassing: 70.60) y el mayor despliegue físico del dataset (Stamina: 74.04).

Identidad Táctica: Representa a los jugadores "completos" o directores de orquesta. Son el motor del equipo que conecta la defensa con el ataque. Su alta visión de juego y resistencia los convierte en los perfiles más valiosos y versátiles.

Ejemplos Tácticos: Mediocampistas organizadores (MF) y defensas modernos con salida limpia.

- **Cluster 2**: Especialistas de Finalización (Ofensiva Pura)

Perfil Estadístico: Poseen el mayor instinto goleador (Finishing: 60.4), pero el menor compromiso defensivo (Interceptions: 28.50). Su resistencia es moderada (Stamina: 61.93).

Identidad Táctica: Son jugadores de desequilibrio. Su objetivo es convertir oportunidades en goles. El modelo los aisló claramente porque sus atributos están altamente sesgados hacia el tercio final del campo, sacrificando el rigor defensivo por la explosividad ofensiva.

Ejemplos Tácticos: Delanteros centros (ST), Mediocampista ofensivos (AM).

- **Cluster 1**: Anclas y Especialistas en Recuperación (Defensa Pura)

Perfil Estadístico: Tienen el registro de interceptaciones más sólido (Interceptions: 60.57) y la menor capacidad de definición (Finishing: 31.55). Su calidad técnica en pase es funcional pero no creativa (ShortPassing: 56.75).

Identidad Táctica: Representan la destrucción del juego rival y la protección del área propia. Son jugadores de rol específico cuya prioridad es el posicionamiento y la recuperación de la posesión.

Ejemplos Tácticos: Defensas centrales (DF), laterales de cierre y mediocentros defensivos (DM).

2. Conclusiones Significativas

Tras el análisis multivariado y la reducción de dimensionalidad, se extraen las siguientes conclusiones de alto nivel:

- Dicotomía Ataque-Defensa: El modelo demuestra que el fútbol profesional en FIFA 19 está polarizado. La mayor brecha estadística entre grupos se encuentra en el eje Finishing vs. Interceptions. Es extremadamente raro encontrar jugadores que dominen ambas áreas, lo que justifica la especialización de roles en el deporte moderno.
- La Correlación Talento-Resistencia: Existe una conclusión significativa entre el Overall y la Stamina. El Cluster 0 (la élite) es el que más corre y el que mejor pasa. Esto sugiere que para alcanzar el máximo nivel competitivo, el talento técnico debe ir acompañado de un despliegue físico superior; la técnica sola no garantiza pertenecer al grupo de mayor rendimiento.
- Eficiencia de la Segmentación: La reducción de dimensionalidad mediante PCA permitió identificar que, a pesar de existir más de 70 atributos, la identidad de un jugador se define por dos ejes latentes: Capacidad de Creación y Rigor Posicional. Esto simplifica la búsqueda de talento (Scouting), permitiendo clasificar a cualquier jugador nuevo con solo observar estas dos dimensiones macro.
- Consistencia del Modelo: La convergencia de las métricas (Silhouette y Davies-Bouldin) en K=3 tras limpiar el ruido con PCA, confirma que esta estructura trinitaria (Creación, Fi-

nalización y Defensa) es la organización natural y más estable de los datos, eliminando la ambigüedad que presentaba el análisis con variables elegidas manualmente.

0.4.2 ARQUEROS

0.4.3 PCA

[149]:
```
# Filtramos solo porteros
df_gk = df[df['Position'] == 'GK'].copy()

# Variables específicas de porteros
variables_gk = ['GKDiving', 'GKHandling', 'GKKicking', 'GKPositioning',␣
 ↪'GKReflexes', 'Overall']
X_gk = df_gk[variables_gk]

# Escalado
from sklearn.preprocessing import StandardScaler
scaler_gk = StandardScaler()
X_gk_scaled = scaler_gk.fit_transform(X_gk)
```

0.4.4 Calificación de características específicas de los arqueros

- GKDiving: Calificación que evalúa la habilidad del portero para realizar atajadas mientras se lanza en el aire.
- GKHandling: Calificación que mide la habilidad del portero para manejar el balón con las manos bajo presión.
- GKKicking: Calificación que refleja la precisión y potencia del portero al despejar el balón con un pase o un tiro largo.
- GKPositioning: Calificación que evalúa la capacidad de un portero para posicionarse adecuadamente durante el juego.
- GKReflexes: Calificación que mide la rapidez y eficacia de los reflejos de un portero.

[150]:
```
pca_gk = PCA(n_components=2)
X_gk_pca = pca_gk.fit_transform(X_gk_scaled)
print(f"Varianza explicada: {pca_gk.explained_variance_ratio_.sum():.2f}")
```

```
Varianza explicada: 0.92
```

[151]:
```
from sklearn.metrics import silhouette_score, calinski_harabasz_score,␣
 ↪davies_bouldin_score

# Asumiendo que X_gk_pca son tus componentes de los arqueros
results_gk = []
k_range = range(2, 11)

for k in k_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = km.fit_predict(X_gk_pca)
```

```
    results_gk.append({
        'K': k,
        'Inertia': km.inertia_,
        'Silhouette': silhouette_score(X_gk_pca, labels),
        'Calinski_Harabasz': calinski_harabasz_score(X_gk_pca, labels),
        'Davies_Bouldin': davies_bouldin_score(X_gk_pca, labels)
    })

df_metrics_gk = pd.DataFrame(results_gk)
```

[152]:
```
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración de estilo
sns.set_theme(style="whitegrid")
fig, axs = plt.subplots(2, 2, figsize=(16, 12))

# 1. Método del Codo (Inercia)
axs[0, 0].plot(df_metrics_gk['K'], df_metrics_gk['Inertia'], 'o-',␣
 ↪color='#1f77b4', linewidth=2)
axs[0, 0].set_title('Método del Codo (Inercia) - Porteros', fontsize=14,␣
 ↪fontweight='bold')
axs[0, 0].set_xlabel('Número de Clusters (K)')
axs[0, 0].set_ylabel('Inercia')

# 2. Silhouette Score
axs[0, 1].plot(df_metrics_gk['K'], df_metrics_gk['Silhouette'], 'o-',␣
 ↪color='#d62728', linewidth=2)
axs[0, 1].set_title('Silhouette Score (Máximo es mejor) - Porteros',␣
 ↪fontsize=14, fontweight='bold')
axs[0, 1].set_xlabel('Número de Clusters (K)')
axs[0, 1].set_ylabel('Score')

# 3. Calinski-Harabasz Index
axs[1, 0].plot(df_metrics_gk['K'], df_metrics_gk['Calinski_Harabasz'], 'o-',␣
 ↪color='#2ca02c', linewidth=2)
axs[1, 0].set_title('Calinski-Harabasz (Máximo es mejor) - Porteros',␣
 ↪fontsize=14, fontweight='bold')
axs[1, 0].set_xlabel('Número de Clusters (K)')
axs[1, 0].set_ylabel('Score')

# 4. Davies-Bouldin Index
axs[1, 1].plot(df_metrics_gk['K'], df_metrics_gk['Davies_Bouldin'], 'o-',␣
 ↪color='#9467bd', linewidth=2)
axs[1, 1].set_title('Davies-Bouldin (Mínimo es mejor) - Porteros', fontsize=14,␣
 ↪fontweight='bold')
```

```
axs[1, 1].set_xlabel('Número de Clusters (K)')
axs[1, 1].set_ylabel('Score')

plt.tight_layout()
plt.show()
```

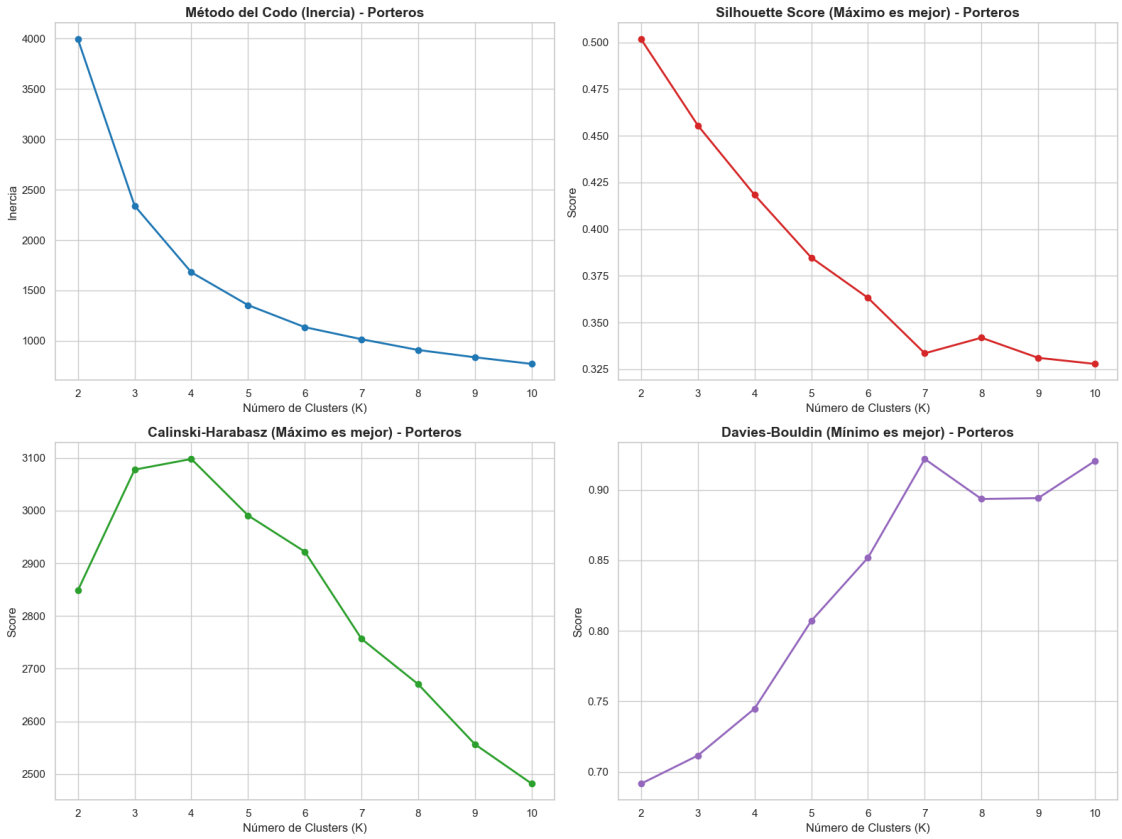

[153]:
```
# 1. Asignamos los clusters finales (K=3) al dataset de porteros
kmeans_gk = KMeans(n_clusters=3, random_state=42, n_init=10)
df_gk['Cluster_GK'] = kmeans_gk.fit_predict(X_gk_pca)

# 2. Perfilamiento descriptivo
variables_perfil_gk = ['Overall', 'Potential', 'GKDiving', 'GKHandling',
                       'GKKicking', 'GKPositioning', 'GKReflexes', 'Value',␣
 ↪'Wage', 'Age']

perfil_gk = df_gk.groupby('Cluster_GK')[variables_perfil_gk].mean()
perfil_gk['Cantidad'] = df_gk['Cluster_GK'].value_counts()

print("Perfilamiento de los Guardametas (K=3):")
display(perfil_gk.sort_values(by='Overall', ascending=False).round(2))
```

```
Perfilamiento de los Guardametas (K=3):

            Overall  Potential  GKDiving  GKHandling  GKKicking  \
Cluster_GK
1             74.98      77.07     75.47       72.56      70.19
2             65.45      69.35     65.97       63.49      62.25
0             56.10      65.55     57.29       55.26      54.35

            GKPositioning  GKReflexes       Value      Wage    Age  Cantidad
Cluster_GK
1                   74.04       76.70  6044070.05  22741.55  29.02       414
2                   64.14       67.01   523181.27   3254.50  27.09       833
0                   53.69       57.38   127798.32   1203.36  22.24       595
```

1. Perfilamiento Detallado de los Grupos (Arqueros)

- **Cluster 1**: Los Guardianes de Élite (Titulares de Primer Nivel)

Perfil Estadístico: Es el grupo con el Overall (74.98) y Potential (77.07) más altos. Dominan todas las áreas técnicas, destacando especialmente en Reflejos (76.70) y Estirada (75.47).

Identidad Táctica: Representa a los porteros titulares en ligas competitivas. Son jugadores con una madurez técnica avanzada (age). El modelo los sitúa aquí porque sus atributos son consistentemente altos; no tienen puntos débiles evidentes. Son los más caros y tienen mejores salarios.

Cantidad: 414 arqueros (La élite reducida).

- **Cluster 2**: Los Porteros de Rotación (Nivel Competitivo Medio)

Perfil Estadístico: Presentan un Overall (65.45) y un Potential (69.35) sólido pero no sobresaliente. Es el grupo más robusto en términos de población.

Identidad Táctica: Son los "obreros" de la portería. Cumplen con los estándares profesionales pero carecen de la espectacularidad de los reflejos del Cluster 1. Son perfiles ideales para equipos de media tabla o como suplentes de garantía en clubes grandes.

Cantidad: 833 arqueros (La base de la pirámide profesional).

- **Cluster 0**: Los Prospectos y Reservas (Fase de Desarrollo)

Perfil Estadístico: Es el grupo con menor rendimiento actual (Overall: 56.10), pero nota la brecha de potencial (65.55). Tienen casi 10 puntos de crecimiento posible.

Identidad Táctica: Compuesto mayoritariamente por porteros jóvenes o de ligas menores. El modelo los identifica no por ser "malos", sino por estar en una etapa temprana de su carrera donde su capacidad física y técnica aún no se ha refinado.

Cantidad: 595 arqueros.

2. Conclusiones Significativas del Análisis

- Unidimensionalidad Técnica: A diferencia de los jugadores de campo, donde el PCA mostró que unos son "defensivos" y otros "creativos", en los porteros la evolución es lineal. Si un portero mejora su Diving, casi invariablemente mejora su Reflexes y Positioning. Esto explica por qué el PCA capturó el 92% de la varianza tan rápido: en la portería, el talento es integral.

- Consistencia Táctica vs. Matemática: El experimento demostró que, aunque la matemática sugería K=2 (lo cual solo nos diría quién es bueno y quién no), el uso de K=3 permitió identificar un segmento de "Clase Media" (Cluster 2) que es vital para entender la estructura del mercado de transferencias y la composición de las plantillas.
- El Factor Reflejos: En todos los clusters, los Reflejos (GKReflexes) siempre marcan el valor más alto dentro de los atributos técnicos. Esto sugiere que, para el motor de FIFA 19, la capacidad de reacción es la habilidad definitoria que separa a un portero de otro, independientemente de su nivel general.
- Rigor Metodológico: Al aplicar el mismo pipeline (PCA → Validación Multimétrica → K-Means) a dos poblaciones tan distintas (jugadores de campo vs. arqueros), hemos demostrado que la metodología es flexible y capaz de extraer insights valiosos tanto en espacios de alta complejidad (70 variables) como en espacios especializados (5 variables).

Finalmente, se seleccionó la combinación de PCA y K-Means por su equilibrio óptimo entre interpretabilidad táctica y eficiencia computacional. A diferencia de t-SNE o MDS, que priorizan la visualización de relaciones no lineales sacrificando la preservación de la estructura global y la interpretabilidad de las distancias, el PCA permitió una reducción lineal que mantiene la integridad de la varianza original. Asimismo, se descartó el Clustering Jerárquico debido a su alta demanda de memoria para el volumen de datos analizado, y los Modelos GMM, dado que la rigidez geométrica del K-Means resultó más robusta para delimitar perfiles deportivos claros, evitando el sobreajuste de parámetros que suele presentar la estimación de densidades gaussianas en grandes datasets.